

UNIVERSIDAD SANTO TOMAS
PRIMER CLAUSTRO UNIVERSITARIO DE COLOMBIA

Propuesta de solución basada en la nube

Adrian Grateron, Jhonatan Smith Doncel Murillo, Jorge Emmanuel Marin

Facultad de estadística

Universidad Santo Tomas

Seccional Bogotá

Big Data

septiembre 2026

Contenido

1. Contexto y Objetivos..... 3
1.1. Contexto del Problema..... 3
1.2. Definición de conjunto de datos..... 3
1.3. Análisis y diseño de la Variable Objetivo..... 4
1.4. Objetivo general..... 5
1.5. Objetivos específicos..... 5
2. Arquitectura preliminar..... 5
2.1. Fuente de datos..... 7
2.2. Capa Bronze..... 7
2.3. Capa Silver..... 7
2.4. Capa Gold..... 8
2.5. Pipeline de Machine Learning..... 8
3. Justificación Tecnológica..... 9
3.1. Databricks / Apache Spark..... 9
3.2. Delta Lake:..... 9
3.3. PySpark SQL & Window Functions..... 10
3.4. Spark MLlib..... 10
4. Herramientas de Visualización..... 11
5. Evaluación de Modelos (Propuesta Metodológica)..... 11
5.1. División temporal de los datos..... 11
5.2. Definición del umbral de variación..... 12
5.3. Modelos propuestos..... 12
Regresión Logística..... 13
Random Forest..... 13
5.4. Métricas de evaluación..... 13
Precisión..... 13
Recall..... 14
F1-Score..... 14
ROC AUC..... 14
PR AUC..... 14
5.5. Comparación final..... 14
5.6. Resultados esperados..... 15
Referencias Bibliográficas..... 15

1. Contexto y Objetivos

1.1. Contexto del Problema

La seguridad ciudadana en Bogotá genera diariamente una gran cantidad de información relacionada con hechos delictivos, lugares de ocurrencia, características de las víctimas y condiciones asociadas a cada evento. Esta información puede ser utilizada para comprender mejor el comportamiento de los delitos y apoyar procesos de análisis y toma de decisiones.

Para este proyecto se propone utilizar información proveniente del Sistema de Información Estadístico, Delincuencial, Contravencional y Operativo (SIEDCO), correspondiente al periodo comprendido entre enero de 2018 y julio de 2026.

La base disponible contiene 368.651 registros, lo que hace necesario contar con una estructura que facilite su almacenamiento, transformación y análisis.

1.2. Definición de conjunto de datos

Para el desarrollo del proyecto se utilizará la base de datos SIEDCO, extraída el 3 de agosto de 2026, con información comprendida entre enero de 2018 y julio de 2026.

La base contiene variables relacionadas con las características de los hechos registrados, entre ellas:

- Tipo de hecho delictivo
- Localidad
- Sexo
- Arma utilizada
- Rango de edad
- Franja horaria
- Cantidad de casos

A partir de estas variables se propone construir series temporales mensuales para cada combinación de localidad y hecho delictivo.

Por ejemplo, una serie podría representar el comportamiento mensual del hurto a personas en Kennedy, mientras otra podría corresponder al mismo delito en Suba.

Esta organización permitirá analizar cada combinación de localidad y hecho como una serie independiente y estudiar su comportamiento a través del tiempo.

1.3. Análisis y diseño de la Variable Objetivo

La pregunta principal que orientará el proyecto es:

¿Es posible anticipar, a partir del comportamiento histórico reciente de los delitos, si una combinación de localidad y hecho delictivo presentará una variación alta durante el mes siguiente?

Para responder esta pregunta se propone analizar el comportamiento mensual de cada serie localidad–hecho.

Una dificultad importante es que algunas series pueden presentar meses con cero casos registrados. Por esta razón, utilizar cambios porcentuales tradicionales puede generar problemas, principalmente cuando el valor del periodo anterior es igual a cero.

Como alternativa, se propone utilizar diferencias logarítmicas:

$$\Delta \ln\left(casos_{i,t,k}\right) = \ln\left(1 + casos_{i,t}\right) - \ln\left(1 + casos_{i,t-k}\right)$$

donde:
i = series localidades- hecho
t = mes actual
k= número de meses de rezago

El uso de 1+casos permite aplicar el logaritmo incluso cuando una serie presenta cero casos en determinado mes.

A partir de estos cambios se propone construir una variable objetivo binaria denominada:

target_high_variation_next_month

Esta variable permitirá clasificar cada observación en dos grupos:

$$Y = \left\{\frac{1 \ (si\ el\ cambio\ del\ mes\ siguiente\ es\ considerado\ alto)}{0\ (Caso\ contrario)}\right\}$$

Para establecer qué se considera una variación alta, se propone utilizar el percentil 75 de la distribución de los cambios absolutos.

Este umbral será calculado únicamente con la información correspondiente al conjunto de entrenamiento. De esta manera se evitará utilizar información futura durante la construcción del modelo, lo que podría generar fuga de información o *data leakage*.

1.4. Objetivo general

Diseñar una solución de análisis de datos basada en una arquitectura Lakehouse que permita procesar información histórica de SIEDCO y evaluar modelos de clasificación para identificar posibles variaciones altas en el comportamiento mensual de los delitos en Bogotá.

1.5. Objetivos específicos

- Diseñar una arquitectura de datos tipo Medallion, organizada en capas Bronze, Silver y Gold, utilizando Databricks, Apache Spark y Delta Lake.
- Preparar y transformar la información histórica de SIEDCO con el fin de construir series temporales mensuales por localidad y tipo de hecho delictivo.
- Construir variables temporales que permitan representar el comportamiento reciente de las series, utilizando rezagos, cambios logarítmicos, medias móviles y medidas de volatilidad.
- Evaluar modelos de clasificación supervisada, específicamente Regresión Logística y Random Forest, para identificar si el mes siguiente puede presentar una variación alta.
- Comparar el desempeño de los modelos utilizando métricas como Precision, Recall, F1-Score, ROC AUC y PR AUC.

2. Arquitectura preliminar

Para organizar el procesamiento de la información se propone utilizar una arquitectura Medallion.

Esta arquitectura permitirá separar el flujo de datos en tres niveles: (metodología medallion) Bronze, Silver y Gold.

Cada capa tendrá una función diferente dentro del procesamiento.

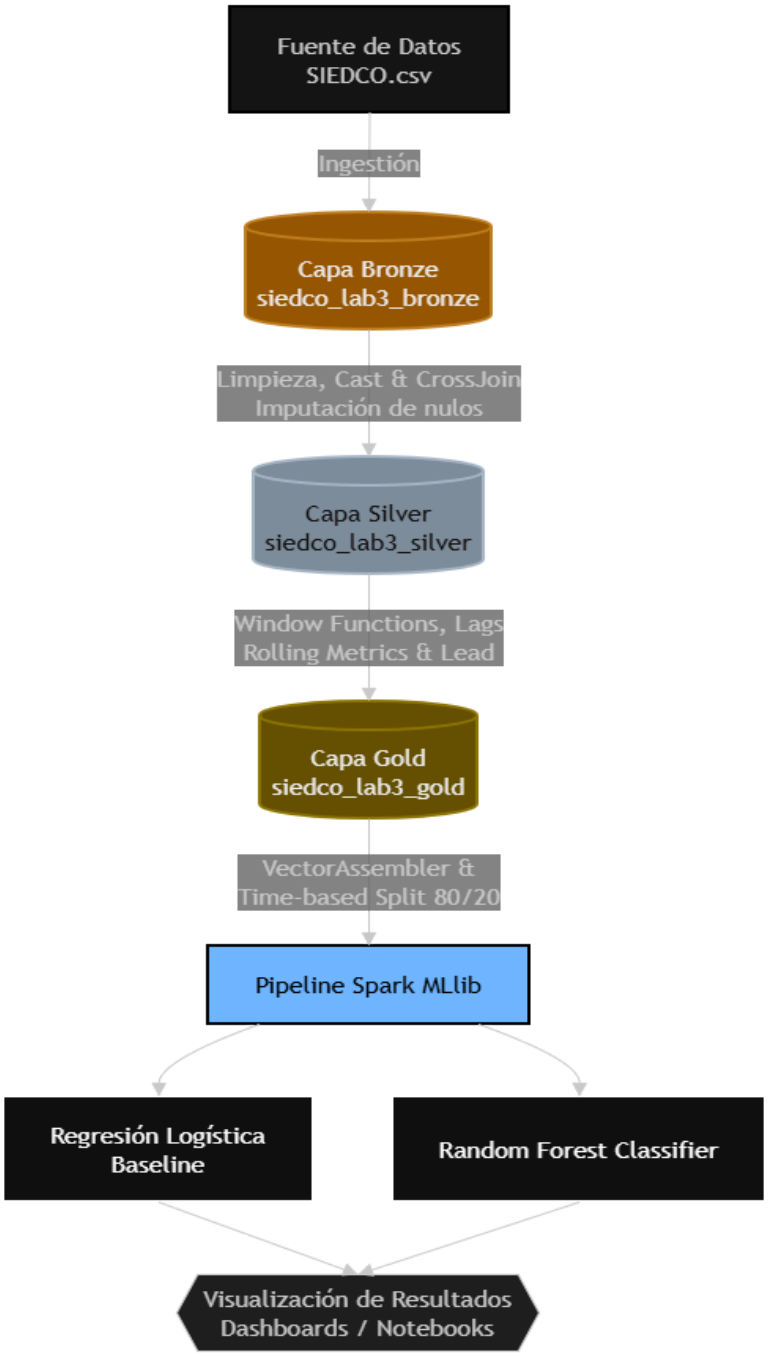


Figura 1. Diagrama del pipeline de procesamiento Lakehouse Medallion y flujo de modelado distribuido en Spark MLlib.

2.1. Fuente de datos

La información inicial provendrá del archivo SIEDCO utilizado para el desarrollo del proyecto.

Este archivo contiene los registros históricos relacionados con los diferentes hechos delictivos registrados en Bogotá.

Entre las variables disponibles se encuentran información relacionada con:

- Sexo
- Tipo de hecho
- Localidad
- Arma utilizada
- Rango de edad
- Franja horaria
- Número de casos

Esta información constituirá el punto de partida del proceso.

2.2. Capa Bronze

La capa Bronze tendrá como propósito conservar la información original sin realizar modificaciones importantes sobre los datos.

En esta etapa se almacenará una copia de la fuente inicial utilizando formato Delta.

También se propone agregar información relacionada con la trazabilidad de los registros, como:

- Fecha y hora de carga
- Fuente de origen
- Identificador del proceso de ingestión

Esta capa permitirá conservar una versión de referencia de los datos originales.

2.3. Capa Silver

La capa Silver estará orientada a la limpieza y organización de los datos.

En esta etapa se realizarán procesos como:

- Revisión de valores nulos
- Corrección de tipos de datos
- Estandarización de textos

- Validación de fechas
- Agrupación de registros
- Construcción de series temporales

Posteriormente, se propone agrupar la información por mes, localidad y tipo de hecho delictivo.

También se construirá un calendario continuo para cada serie.

Esto permitirá identificar los meses en los que no se hayan registrado casos y, cuando corresponda, asignar un valor de cero.

Adicionalmente, se podrá establecer un número mínimo de meses con información para conservar únicamente las series que tengan suficiente historial para el análisis.

2.4. Capa Gold

La capa Gold estará orientada a la preparación de los datos para el proceso de Machine Learning.

En esta etapa se construirán variables que permitan representar el comportamiento reciente de cada serie.

Entre las variables propuestas se encuentran:

- Rezagos temporales
- Cambios logarítmicos
- Medias móviles
- Medidas de volatilidad
- Cambios en los casos ocurridos durante la noche
- Cambios relacionados con hechos en los que se registren armas de fuego
- Relaciones entre los valores actuales y sus medias móviles

Estas variables serán utilizadas posteriormente como características de entrada para los modelos de clasificación.

2.5. Pipeline de Machine Learning

Después de construir la capa Gold, se propone desarrollar un pipeline de Machine Learning utilizando Spark MLlib.

El proceso incluirá:

1. Selección de variables
2. Transformación de variables categóricas

3. Construcción del vector de características
4. División temporal de los datos
5. Entrenamiento de los modelos
6. Generación de predicciones
7. Evaluación del desempeño

Se propone mantener este proceso dentro de un pipeline para facilitar su reproducibilidad y reducir diferencias entre las etapas de entrenamiento y evaluación.

3. Justificación Tecnológica

3.1. Databricks / Apache Spark

Databricks será utilizado como entorno principal para el desarrollo del proyecto.

La plataforma permite integrar almacenamiento, procesamiento, análisis y modelado dentro de un mismo entorno.

Apache Spark permitirá realizar transformaciones sobre los datos utilizando procesamiento distribuido.

Aunque el tamaño actual de la información podría ser manejado utilizando otras herramientas, el uso de Spark permitirá diseñar una solución que pueda escalar si posteriormente aumenta el volumen de datos.

3.2. Delta Lake:

Delta Lake será utilizado como formato de almacenamiento para las diferentes capas de la arquitectura.

Una de sus principales ventajas es que permite combinar características propias de los sistemas de almacenamiento de grandes volúmenes de datos con funcionalidades relacionadas con el control y consistencia de la información.

Entre sus beneficios se encuentran:

- Transacciones ACID
- Control de versiones
- Manejo de esquemas
- Recuperación de versiones anteriores
- Integración con Spark

Estas características pueden facilitar la trazabilidad del procesamiento realizado durante el proyecto.

3.3. PySpark SQL & Window Functions

PySpark SQL será utilizado para realizar las principales transformaciones sobre la información.

Las funciones de ventana o Window Functions tendrán especial importancia en la construcción de variables temporales.

Estas funciones permiten realizar cálculos dentro de cada serie sin mezclar la información de diferentes localidades o tipos de hecho.

Por ejemplo, permitirán comparar el número de casos registrados en un mes con el comportamiento observado en meses anteriores.

También facilitarán la construcción de:

- Rezagos
- Medias móviles
- Medidas de volatilidad
- Cambios temporales

3.4. Spark MLlib

Spark MLlib será utilizado para desarrollar los modelos de Machine Learning.

Su principal ventaja dentro del proyecto es que permite mantener el flujo de preparación y modelado de los datos dentro del mismo ecosistema tecnológico.

Con MLlib se propone implementar:

- Regresión Logística
- Random Forest
- Transformación de variables
- Construcción de vectores
- Generación de predicciones
- Evaluación de modelos

4. Herramientas de Visualización

La visualización tendrá un papel importante dentro del proyecto, tanto para explorar la información como para presentar los resultados de los modelos.

Se propone utilizar las visualizaciones disponibles directamente en Databricks mediante la función display().

También podrán utilizarse librerías de Python como:

- Pandas
- Matplotlib
- Seaborn
- Plotly
- Numpy
- Scikit-learn

Estas herramientas permitirán construir diferentes tipos de visualizaciones.

Por ejemplo, se podrán utilizar gráficos de series de tiempo para observar la evolución mensual de los delitos.

También se podrán construir mapas de calor para comparar las métricas obtenidas por los diferentes modelos.

Las matrices de confusión permitirán observar con mayor detalle los errores y aciertos de clasificación.

Las curvas ROC y Precision-Recall permitirán analizar el comportamiento de los modelos frente a diferentes puntos de corte.

En el caso de Random Forest, también será posible representar la importancia relativa de las variables utilizadas durante el entrenamiento.

Estas visualizaciones permitirán complementar las métricas numéricas y facilitar la interpretación de los resultados.

5. Evaluación de Modelos (Propuesta Metodológica)

5.1. División temporal de los datos

Debido a que los datos tienen una estructura temporal, se propone evitar una división aleatoria convencional entre entrenamiento y prueba.

En su lugar, se utilizará una separación cronológica.

Los periodos más antiguos serán utilizados para entrenar los modelos, mientras que los periodos más recientes serán utilizados para evaluar su desempeño.

De manera general, se propone utilizar aproximadamente:

- 80% de los periodos para entrenamiento
- 20% de los periodos para prueba

Esta separación permitirá simular de una forma más cercana un escenario real, en el cual se utiliza información histórica para intentar anticipar el comportamiento futuro.

También permitirá reducir el riesgo de utilizar información posterior para explicar observaciones anteriores

5.2. Definición del umbral de variación

Para construir la variable objetivo será necesario determinar qué nivel de cambio será considerado una variación alta.

Se propone utilizar como referencia el percentil 75 de la distribución de los cambios absolutos.

El valor del percentil será calculado con el conjunto de entrenamiento.

Posteriormente, este mismo umbral será utilizado para clasificar las observaciones del conjunto de prueba.

Este procedimiento busca evitar que la información correspondiente al periodo de evaluación influya en la construcción de la variable objetivo.

5.3. Modelos propuestos

Para el análisis se propone comparar dos modelos de clasificación:

- Regresión Logística
- Random Forest

La intención no será asumir desde el inicio que uno de los modelos será superior.

Ambos serán evaluados bajo las mismas condiciones y utilizando las mismas particiones temporales.

Regresión Logística

La Regresión Logística será utilizada como un modelo de referencia.

Su principal ventaja es que tiene una estructura relativamente sencilla y sus resultados pueden ser interpretados con mayor facilidad.

Su inclusión permitirá establecer una línea base para evaluar si un modelo más flexible produce mejoras en la capacidad de clasificación.

Random Forest

Random Forest será utilizado como una alternativa capaz de capturar relaciones no lineales entre las variables.

Este modelo combina varios árboles de decisión y puede identificar interacciones entre diferentes características.

Esto podría resultar útil en este proyecto, ya que el comportamiento de una serie podría depender simultáneamente de elementos como:

- Cambios recientes
- Medias móviles
- Volatilidad
- Comportamiento nocturno
- Uso de armas
- Características propias de cada serie

La utilidad real de este modelo deberá determinarse a partir de los resultados obtenidos durante la evaluación.

5.4. Métricas de evaluación

El desempeño de los modelos no será evaluado únicamente mediante Accuracy.

Esto se debe a que la variable objetivo podría presentar un desbalance entre los casos normales y aquellos clasificados como variaciones altas.

Por esta razón, se propone utilizar varias métricas.

Precisión

La precisión permitirá conocer qué proporción de las observaciones clasificadas como variación alta realmente pertenecen a esa categoría.

$$precisión = \frac{TP}{TP + FP}$$

Recall

El Recall permitirá identificar qué proporción de las variaciones altas reales fueron detectadas por el modelo.

$$Recall = \frac{TP}{TP + FN}$$

Esta métrica puede resultar especialmente importante si el propósito es identificar la mayor cantidad posible de cambios relevantes.

F1-Score

El F1-Score combina Precisión y Recall en una sola medida.

Esta métrica permitirá evaluar el equilibrio entre la capacidad de detectar variaciones altas y la generación de falsos positivos.

$$F1 = 2\,\frac{Precisión * Recall}{Precision + Recall}$$

ROC AUC

El ROC AUC permitirá evaluar la capacidad general del modelo para diferenciar entre las dos clases a distintos niveles de decisión.

PR AUC

El PR AUC será utilizado como una medida complementaria, especialmente útil cuando exista desbalance entre las clases.

5.5. Comparación final

La comparación entre Regresión Logística y Random Forest se realizará teniendo en cuenta el conjunto completo de métricas.

No se propone seleccionar un modelo únicamente por tener un Accuracy mayor.

También será necesario analizar:

- Cuántas variaciones altas logra identificar
- Cuántos falsos positivos genera

- Cuántos eventos relevantes deja de detectar
- Qué tan estable es su desempeño en el periodo de prueba

A partir de estos resultados se determinará cuál modelo presenta un comportamiento más adecuado para el problema planteado.

5.6. Resultados esperados

Como resultado del proyecto se espera obtener una arquitectura de datos organizada que permita transformar los registros originales de SIEDCO en información preparada para análisis temporal y modelado.

También se espera construir un conjunto de variables que represente el comportamiento histórico reciente de las series de delitos.

En términos analíticos, se busca determinar si las variables construidas a partir del comportamiento pasado contienen suficiente información para identificar períodos en los que pueda presentarse una variación alta durante el mes siguiente.

El proyecto también permitirá comparar el comportamiento de un modelo lineal, como la Regresión Logística, frente a un modelo basado en árboles, como Random Forest.

Más que buscar únicamente un modelo con buen desempeño estadístico, se pretende evaluar si los resultados pueden ser interpretados y utilizados como apoyo para el análisis de información relacionada con seguridad ciudadana.

Referencias Bibliográficas

Balusamy, B. et al. *Big Data Processing and Visualization*.

Databricks Documentation: *Delta Lake Guide & Spark MLlib Pipelines*.

Secretaría Distrital de Seguridad, Convivencia y Justicia. (2026). SIEDCO delitos de alto impacto. Información consultada el 3 de agosto de 2026, con corte al 31 de julio de 2026.

Apache Software Foundation. (s. f.). Apache Spark documentation. https://spark.apache.org/docs/latest/